Objetivo

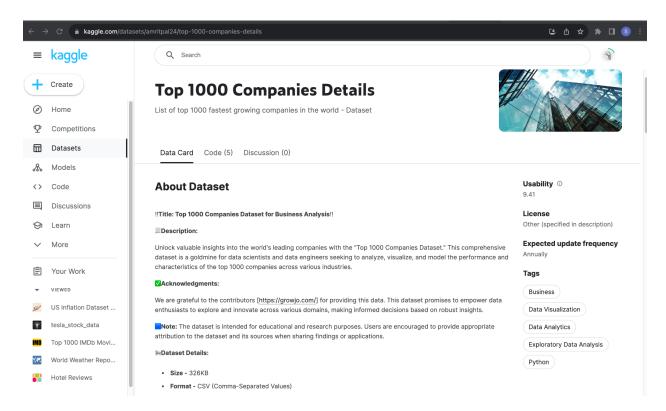
A partir de dados sobre as empresas que mais crescem no mundo, analisar:

1. Quantos colaboradores possui a empresa com o maior faturamento esperado?

Detalhamento

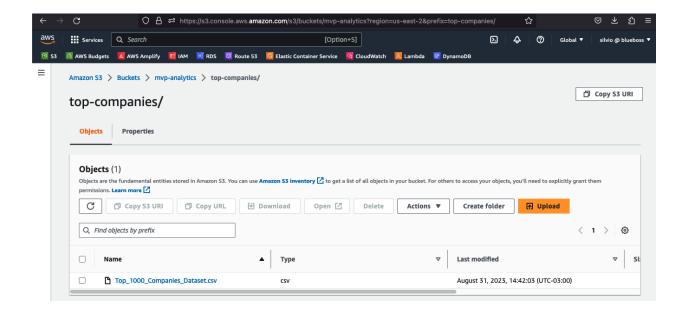
Busca pelos dados

https://www.kaggle.com/datasets/amritpal24/top-1000-companies-details



Coleta

Dados baixados para a máquina local e inseridos manualmente em um bucket do S3.

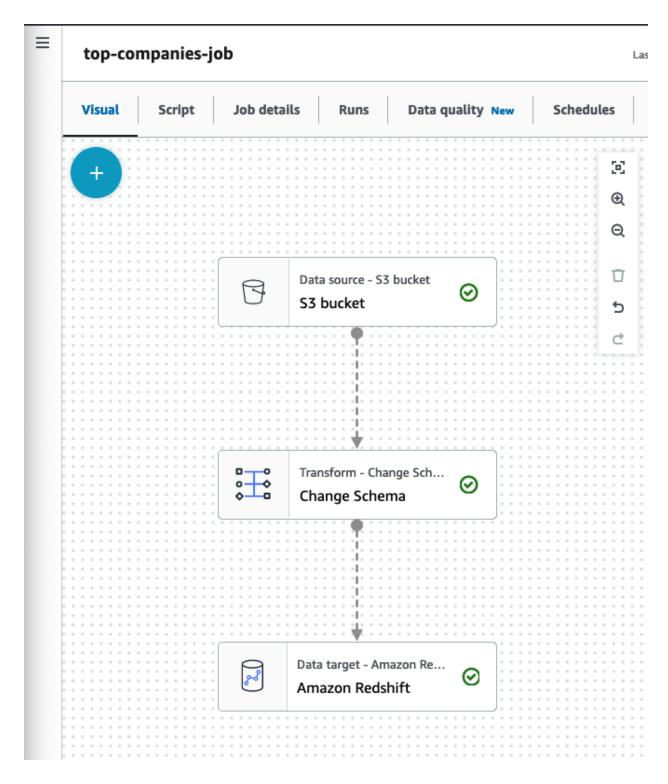


Modelagem

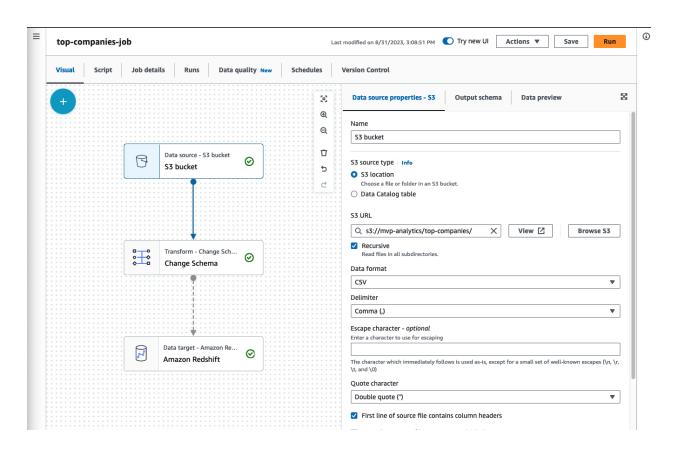
. . .

Carga

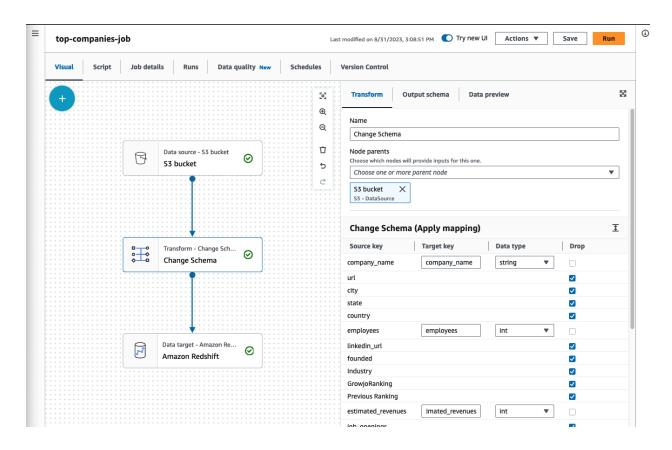
O ETL foi realizado utilizando o serviço AWS Glue. Através de sua interface visual foram criadas as seguintes etapas:



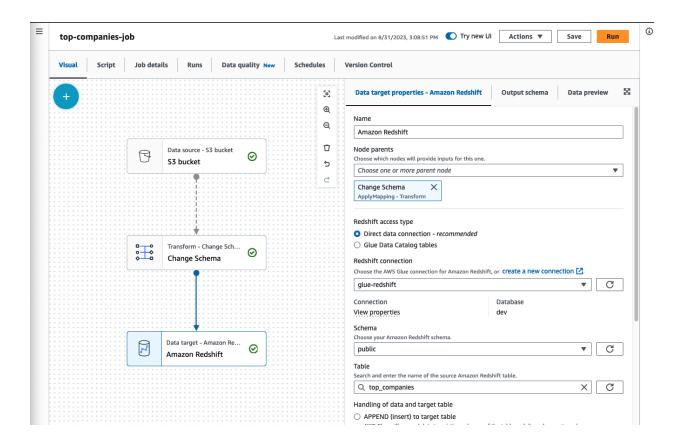
Na etapa 1, "Data source - S3 bucket", foram realizadas as configurações para extrair (*Extract*) os dados da fonte, no caso a pasta "top-companies" do bucket "mvp-analytics".



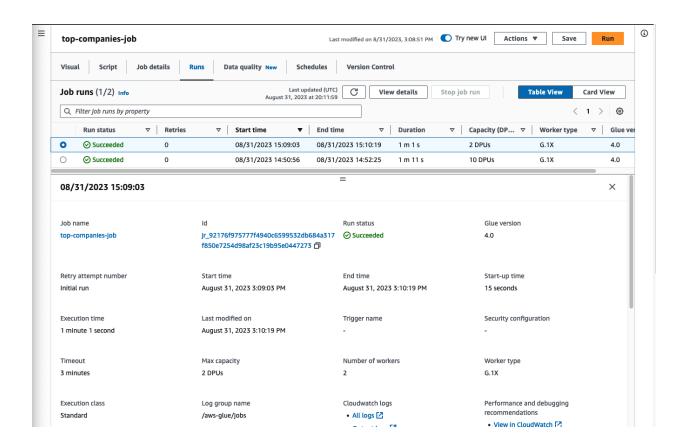
Na etapa 2, "Transform - Change Schema", realizamos a etapa de transformação (*Transform*) dos dados, convertendo os tipos dos campos "employees" e "estimated_revenues" para int.



Já na terceira etapa, "Data target - Amazon Redshift", configuramos os parâmetros necessários para o carregamento (*Load*) dos dados transformados no nosso banco de dados.



Por último, registramos a execução dos jobs após todas as configurações.



Análise

Qualidade de dados

. . .

Solução do problema

